

# Experimentos de Um Fator

- Objetivo: comparar  $a$  alternativas ( $a \geq 2$ ) de uma única variável categórica
  - Comparar impacto de diferentes processadores
  - Comparar impacto de diferentes algoritmos para um mesmo problema
  - Comparar diferentes políticas de caching
- Não há limites no número de níveis para o fator analisado

# Experimentos de Um Fator

- Modelo:  $y_{ij} = \mu + \alpha_j + e_{ij}$ 
  - $y_{ij}$ : i-esima resposta com o fator no nível j
  - $\mu$ : resposta media
  - $\alpha_j$ : efeito da alternativa j
  - $e_{ij}$ : erro experimental
- Tem-se que:

$$\sum_j \alpha_j = 0 \quad \text{e} \quad \sum_i e_{ij} = 0$$

# Computando os Efeitos

- Se  $y_{ij} = \mu + \alpha_j + e_{ij}$  , tem-se que:

$$\sum_{i=1}^r \sum_{j=1}^a y_{ij} = ar\mu + r \sum_{j=1}^a \alpha_j + \sum_{i=1}^r \sum_{j=1}^a e_{ij} = ar\mu + 0 + 0$$

$$\mu = \frac{1}{ar} \sum_{i=1}^r \sum_{j=1}^a y_{ij} = \overline{y_{..}} : \text{media geral}$$

# Computando os Efeitos

$$\begin{aligned}\overline{y_{.j}} &= \frac{1}{r} \sum_{i=1}^r y_{ij} = \frac{1}{r} \sum_{i=1}^r (\mu + \alpha_j + e_{ij}) \\ &= \frac{1}{r} (r\mu + r\alpha_j + \sum_{i=1}^r e_{ij}) = \mu + \alpha_j \\ \alpha_j &= \overline{y_{.j}} - \mu\end{aligned}$$

## Exemplo

- Em uma comparacao de tamanho de codigo, o numero de bytes necessario para codificar uma certa carga em tres processadores diferentes, R, V e Z, foi medido, cada um 5 vezes (diferentes programadores) Os dados medidos sao mostrados na tabela abaixo:

R	144	120	176	288	144
V	101	144	211	288	72
Z	130	180	141	374	302

Assume-se que nao ha dependencia entre as codificacoes feitas para um mesmo processador. Caso contrário, deveria ter sido feito um projeto de 2 fatores

## Exemplo

						Soma da	Media	Efeito
						Linha	Linha	Linha
R	144	120	176	288	144	872	174.4	-13.3
V	101	144	211	288	72	816	163.2	-24.5
Z	130	180	141	374	302	1127	225.4	37.7
					Total	2815	187.7	

Um processador medio requer 187.7 bytes de armazenamento

Em media, proc. R requer 13.3 bytes a menos que a media; V requer 24.5 bytes a menos que a media, e Z requer 37.7 bytes a mais que a media.

# Estimando erros experimentais

$$\hat{y}_j = \mu + \alpha_j \quad e_{ij} = y_{ij} - \hat{y}_j$$

- Variacao dos erros e estimada pela Suma dos Erros Quadrados (SSE)

$$SSE = \sum_{i=1}^r \sum_{j=1}^a e_{ij}^2$$

# Exemplo

$$\begin{bmatrix} 144 & 101 & 130 \\ 120 & 144 & 180 \\ 176 & 211 & 141 \\ 288 & 288 & 374 \\ 144 & 72 & 302 \end{bmatrix} = \begin{bmatrix} 187.7 & 187.7 & 187.7 \\ 187.7 & 187.7 & 187.7 \\ 187.7 & 187.7 & 187.7 \\ 187.7 & 187.7 & 187.7 \\ 187.7 & 187.7 & 187.7 \end{bmatrix} + \begin{bmatrix} -13.3 & -24.5 & 37.7 \\ -13.3 & -24.5 & 37.7 \\ -13.3 & -24.5 & 37.7 \\ -13.3 & -24.5 & 37.7 \\ -13.3 & -24.5 & 37.7 \end{bmatrix} + \\
 + \begin{bmatrix} -30.4 & -62.2 & -95.4 \\ -54.4 & -19.2 & -45.4 \\ 1.6 & 47.8 & -84.4 \\ 113.6 & 124.8 & 148.6 \\ -30.4 & -91.2 & 76.6 \end{bmatrix}$$

$$SSE = (-30.4)^2 + (-54.4)^2 + \dots + (76.6)^2 = 94365.20$$



# Alocacao de Variacao

- Se  $y_{ij} = \mu + \alpha_j + e_{ij}$  , tem-se que:

$$y_{ij}^2 = \mu^2 + \alpha_j^2 + e_{ij}^2 + 2\mu\alpha_j + 2\mu e_{ij} + 2\alpha_j e_{ij}$$

$$\sum_{ij} y_{ij}^2 = \sum_{ij} \mu^2 + \sum_{ij} \alpha_j^2 + \sum_{ij} e_{ij}^2$$

$$SSY = SS0 + SSA + SSE$$

$$SS0 = \sum_{ij} \mu^2 = ar\mu^2 \quad SSA = \sum_{ij} \alpha_j^2 = r \sum_{j=1}^a \alpha_j^2$$

$$SST = \sum_{ij} (y_{ij} - \bar{y}_{..})^2 = SSY - SS0 = SSA + SSE$$

# Exemplo

- $SSY = 144^2 + 120^2 + \dots + 302^2 = 633639$
- $SS0 = ar\mu^2 = 3 * 5 * (187.7)^2 = 528281.7$
- $SSA = r \sum_{j=1}^a \alpha_j^2 = 5[(-13.3)^2 + (-24.5)^2 + (37.6)^2] = 10992.1$
- $SST = SSY - SS0 = 633639 - 528281.7 = 105357.3$
- $SSE = SST - SSA = 105357.3 - 10992.1 = 94365.2$

% variacao explicada pelos processadores:  
 $10992.13 / 105357.3 = 10.4\%$

Resto da variacao devido a erros experimentais

# Analise de Variancia

- O impacto do fator e significativo?
- Precisa comparar a variacao explicada pelo fator com a variacao explicada pelos erros experimentais

# Analise de Variância: Executando Teste F

- Graus de liberdade (df):

$$SSY = SS0 + SSA + SSE$$

$$ar = 1 + (a - 1) + a(r-1)$$

- Quadrados Medios de A e de Erros
  - $MSA = SSA / df(A) = SSA / (a-1)$
  - $MSE = SSE / df(e) = SSE / a(r-1)$
- Computar razão  $MSA / MSE$ : esta razão segue uma distribuição F
  - Se maior que valor da tabela F com  $df=a-1$  no numerador e  $df=a(r-1)$  no denominador e  $1-\alpha$  % de confiança:
    - Fator é significativo com confiança de  $1-\alpha$  %
    - Efeitos explicam fração significativa da variação na resposta (SSA é significativamente maior que SSE)
  - Caso contrario: fator nao é significativo

# Exemplo: Tabela ANOVA

Componente	Soma	% Var.	DF	MS	F	F
	Quadrados				Computado	Tabela
Y	SSY = 633639.00					
y..	SS0 = 528281.69					
y – y..	SST = 105357.31	100	14			
A	SSA = 10992.13	10.4	2	5496.1	0.7	3.89
Erros	SSE = 94365.20	89.6	12	7863.8		

95% confiança

$$s_e = \sqrt{MSE} = \sqrt{7863.77} = 88.68$$


$F_{\text{computado}} < F_{\text{tabela}}$  : diferencas em tamanhos de codigo sao principalmente devido aos “erros experimentais”

# Diagnostico Visual

- Premissas do modelo
  - Efeitos dos fatores sao aditivos
  - Erros sao aditivos
  - Erros sao independentes dos niveis do fator
  - Erros sao normalmente distribuidos
  - Erros tem mesma variancia para todos niveis de fator
- Mesmos testes visuais aplicados a experimentos fatoriais podem ser aplicados aqui para verificar a aplicabilidade do modelo ou entender resultados “estranhos”

# Exemplo

- Grafico de residuos (ou erros) X previsao de resposta



- Residuos nao sao pequenos se comparados com respostas
- Espalhamento no eixo y > espalhamento no eixo x
  - Variacao devido aos erros > variacao devido ao fator
- Espalhamento dos erros e homogeneo e nao ha tendencias claras

# Intervalos de Confiança para Efeitos

<i>Parametro</i>	<i>Estimativa</i>	<i>Variancia</i>	
$\mu$	$\overline{y_{..}}$	$s_e^2 / ar$	
$\alpha_j$	$\overline{y_{.j}} - \overline{y_{..}}$	$s_e^2 (a - 1) / ar$	
$\mu + \alpha_j$	$\overline{y_{.j}}$	$s_e^2 / r$	Estimar IC para resposta media com fator em certo nivel
$\sum_{j=1}^a h_j \alpha_j, \sum_{j=1}^a h_j = 0$	$\sum_{j=1}^a h_j \overline{y_{.j}}$	$\sum_{j=1}^a s_e^2 h_j^2 / r$	
$s_e^2$	$\sum \frac{e_{ij}^2}{a(r-1)}$		Estimar IC para diferenca dos efeitos de niveis do fator (Ex: $\alpha_1 - \alpha_2$ )

**Graus de liberdade dos erros :  $a(r-1)$**



# Exemplo

- Desvio padrao dos parametros

$$s_e^2 = \frac{94365.2}{12} = 7863.8$$

$$\text{Desvio padrao dos erros} = s_e = \sqrt{7863.8} = 88.7$$

$$\text{Desvio padrao de } \mu = s_e / \sqrt{ar} = 88.7 / \sqrt{15} = 22.9$$

$$\text{Desvio padrao de } \alpha_j = s_e \sqrt{(a-1)/(ar)} = 32.4$$

# Exemplo

- 90% IC para os parametros ( $t_{0.95,12} = 1.782$ )

$$\mu = 187.7 \pm (1.782)(22.9) = (146.9, 228.5)$$

$$\alpha_1 = -13.3 \pm (1.782)(32.4) = (-71.0, 44.4)$$

$$\alpha_2 = -24.5 \pm (1.782)(32.4) = (-82.2, 33.2)$$

$$\alpha_3 = 37.6 \pm (1.782)(32.4) = (-20.0, 95.4)$$

Tamanho do código em média e significativamente diferente de 0 (faz sentido)

Porem nenhum dos efeitos dos tres processadores sao significativos. Logo, nao podemos dizer com 90% de confianca que os processadores tem um efeito significativo no tamanho do código

# Exemplo

- Comparando processador R com processador V, computamos IC para  $\alpha_1 - \alpha_2$  (note que  $\sum_j h_j = 0$  )

$$\text{Valor medio para } \alpha_1 - \alpha_2 = \overline{y_{.1}} - \overline{y_{.2}} = 174.4 - 163.2 = 11.2$$

$$\text{Desvio padrao para } \alpha_1 - \alpha_2 = s_e \sqrt{(\sum h_j^2)/r} = 88.7 \sqrt{2/5} = 56.1$$

$$90\% \text{ CI para } \alpha_1 - \alpha_2 = 11.2 \pm (1.782)(56.1) = (-88.7, 111.1)$$

$$\begin{aligned} 90\% \text{ CI para } \alpha_1 - \alpha_3 &= (174.4 - 225.4) \pm (1.782)(56.1) \\ &= (-140.9, 48.9) \end{aligned}$$

$$\begin{aligned} 90\% \text{ CI para } \alpha_2 - \alpha_3 &= (163.2 - 225.4) \pm (1.782)(56.1) \\ &= (-162.1, 37.7) \end{aligned}$$

Todos ICs incluem 0: nenhum proc. é superior

# Amostras de tamanhos diferentes para cada nivel

- Modelo ainda e o mesmo:  $y_{ij} = \mu + \alpha_j + e_{ij}$

- Alem disto:  $\sum_j r_j \alpha_j = 0$

dado que  $r_j$  : numero de replicacoes no nivel j

- Definimos  $N = \sum_j r_j$

# Intervalos de Confiança para Efeitos

<i>Parametro</i>	<i>Estimativa</i>	<i>Variancia</i>
$\mu$	$\overline{y_{..}}$	$s_e^2 / N$
$\alpha_j$	$\overline{y_{.j}} - \overline{y_{..}}$	$s_e^2 (N - r_j) / Nr_j$
$\mu + \alpha_j$	$\overline{y_{.j}}$	$s_e^2 / r_j$
$\sum_{j=1}^a h_j \alpha_j, \sum_{j=1}^a h_j = 0$	$\sum_{j=1}^a h_j \overline{y_{.j}}$	$s_e^2 \sum_{j=1}^a h_j^2 / r_j$
$s_e^2$	$\frac{\sum e_{ij}^2}{N - a}$	

Graus de liberdade dos erros :  $N - a$

# Tabela ANOVA

Componente	Soma	% Var.	DF	MS
	Quadrados			
Y	$SSY = \sum y_{ij}^2$		N	
y..	$SSO = N\mu^2$		1	
y – y..	$SST = SSY - SSO$	100	N-1	
A	$SSA = \sum_j r_j \alpha_j^2$	$100 \frac{SSA}{SST}$	a-1	$MSA = \frac{SSA}{a-1}$
Erros	$SSE = SST - SSA$	$100 \frac{SSE}{SST}$	N-a	$MSE = \frac{SSE}{N-a}$

$$s_e = \sqrt{MSE}$$

$$F_{computado} = \frac{MSA}{MSE}$$

$$F_{tabela} = F_{[1-\alpha, a-1, N-a]}$$

## Exemplo 2

- Suponha que voce descubra que 3 das observacoes no exemplo anterior nao tinham sido obtidas de forma correta. Logo elas nao deveriam ser utilizadas na analise. Das tres observacoes incorretas, suponha que uma seja do sistema V e duas do sistema Z. Agora voce tem entao um projeto de um fator unico com amostras de tamanhos diferentes. Refaca a analise:

## Exemplo 2

						Soma da	Media	Efeito
						Linha	Linha	Linha
R	144	120	176	288	144	872	174.4	2.15
V	101	144	211	288		744	186	13.75
Z	130	180	141			451	150.33	-21.92
Total						2067	172.25	

Um processador medio requer 172.25 bytes de armazenamento

Em media, proc. R requer 2.15 bytes a mais que a media; V requer 13.75 bytes a mais que a media, e Z requer 21.92 bytes a menos que a media.



## Exemplo 2

$$\begin{bmatrix} 144 & 101 & 130 \\ 120 & 144 & 180 \\ 176 & 211 & 141 \\ 288 & 288 & \\ 144 & & \end{bmatrix} = \begin{bmatrix} 172.25 & 172.25 & 172.25 \\ 172.25 & 172.25 & 172.25 \\ 172.25 & 172.25 & 172.25 \\ 172.25 & 172.25 & \\ 172.25 & & \end{bmatrix} + \begin{bmatrix} 2.15 & 13.75 & -21.92 \\ 2.15 & 13.75 & -21.92 \\ 2.15 & 13.75 & -21.92 \\ 2.15 & 13.75 & \\ 2.15 & & \end{bmatrix} + \\
 + \begin{bmatrix} -30.4 & -85.0 & -20.33 \\ -54.4 & -42.0 & 29.67 \\ 1.6 & 25.0 & -9.33 \\ 113.6 & 102.0 & \\ -30.40 & & \end{bmatrix}$$

$$SSE = (-30.4)^2 + (-54.4)^2 + \dots + (-9.33)^2 = 39113.87$$

## Exemplo 2

- $SSY = 144^2 + 120^2 + \dots + 141^2 = 397375$
- $SS0 = N\mu^2 = 12 \cdot (172.25)^2 = 356040.75$
- $SSA = 5\alpha_1^2 + 4\alpha_2^2 + 3\alpha_3^2 = 2220.38$
- $SSE = 39113.87$
- $SST = SSY - SS0 = 41334.25$

% variacao explicada pelos processadores:

$$2220.38 / 41334.25 = 5.4\%$$

Resto da variacao devido a erros experimentais

# Tabela ANOVA

Componente	Soma	% Var.	DF	MS
	Quadrados			
Y	397375.0			
y..	356040.75			
y – y..	41334.25	100	11	
A	2220.38	5.37	2	1110.19
Erros	39113.87	94.63	9	4345.99

$$s_e = \sqrt{MSE} = \sqrt{4345.99} = 65.92$$

$$F_{computado} = \frac{MSA}{MSE} = 0.26 \quad F_{tabela} = F_{[1-\alpha, a-1, N-a]} = 3.01$$

# Sumario

- Ver tabela 20.1 (pagina 341)

# Exercício 1

- Seu melhor amigo acabou de desenvolver um algoritmo revolucionário, chamado Xulambis, para o reconhecimento de ações humanas. Visando uma posterior comparação com o algoritmo estado-da-arte Zambis, ele fez um estudo para estimar a sensibilidade do algoritmo Xulambis, em termos de taxa de reconhecimento (%), aos seus dois parâmetros principais,  $\alpha$  e  $\beta$ . Com base nos resultados de um projeto fatorial (com uma única replicação), mostrado nas 3 primeiras colunas da tabela abaixo, ele concluiu que o algoritmo Xulambis é muito mais sensível ao parâmetro  $\alpha$  que ao parâmetro  $\beta$ , obtendo um desempenho melhor (maior taxa de reconhecimento) para valores mais altos de  $\alpha$ .

Fator $\alpha$	Fator $\beta$	Projeto Fatorial (uma replicação)	Replicações extras	
			2ª replicação	3ª replicação
-1	-1	70%	74%	64%
1	-1	80%	90%	84%
-1	1	45%	34%	43%
1	1	65%	55%	64%

# Exercício 1

- a) Com base apenas na única replicação inicialmente feita (3ª coluna da tabela), você concorda com a conclusão do seu amigo quanto à sensibilidade de Xulambis aos dois parâmetros considerados?
- b) Com base apenas na única replicação inicialmente feita (3ª coluna da tabela), você concorda com a conclusão do seu amigo de que o desempenho de Xulambis é melhor para valores mais altos de  $\alpha$ ?
- c) Conhecendo bem a variabilidade inerente ao problema de reconhecimento de ações humanas, você pede ao seu amigo que execute pelo menos mais 2 replicações para cada cenário. Os resultados são mostrados na 4ª e na 5ª colunas da tabela. Suas conclusões em (a) e (b) se mantêm?
- d) Qual a porcentagem total da variação nos dados, observada no projeto com 3 replicações, você consegue explicar com a variação dos fatores?
- e) Ainda considerando o projeto com 3 replicações, o efeito devido à interação entre os fatores  $\alpha$  e  $\beta$  é significativo com 95% de confiança? Qual a maior confiança que você pode atribuir à afirmativa de que a interação entre os dois fatores é significativa?

## Exercício 2

- Um sistema foi avaliado quanto ao impacto de 4 parâmetros – A, B, C e D. Para tanto, um projeto fatorial  $2^{4-1}$  foi realizado e os resultados são mostrados abaixo. O subscrito representa o nível de cada fator (1 para inferior, e 2 para superior).

	$C_1D_1$	$C_1D_2$	$C_2D_1$	$C_2D_2$
$A_1B_1$	-	40	15	-
$A_1B_2$	-	20	10	-
$A_2B_1$	100	-	-	30
$A_2B_2$	120	-	-	50

- Qual o polinômio gerador deste projeto? Liste todos os *confoundings*, caso existam, e discuta o que eles representam em termos do impacto na precisão do modelo.
- Quantifique todos os efeitos e as porcentagens de variação explicada por cada um deles.
- Você sugeriria um projeto melhor? Qual e por quê?

## Exercício 3

- O tempo de execução de um algoritmo foi avaliado em função de 3 fatores, a CPU (fator A), o tamanho da memória (fator B) e o número de discos (fator C). Foram executadas três replicações para cada configuração considerada, conforme mostrado na tabela abaixo. A tabela também mostra alguns resultados agregados da análise das observações. Responda:

Experimento	I	A	B	C	Tempo de execução(ms)			
					$t_1$	$t_2$	$t_3$	$\bar{t}$
1	1	-1	-1	1	98	100	102	100
2	1	1	-1	-1	245	249	256	250
3	1	-1	1	-1	45	54	52	50
4	1	1	1	1	300	301	299	300
Total	700	400	0	100				
Total/4	175	100	0	25				

$$SSE = 117$$



# Exercício 3

- (a) Qual o polinômio gerador deste projeto? Liste todos os confoundings, caso existam, e discuta o que eles representam em termos do impacto na precisão do modelo?
- (b) Quais são as estimativas e desvios padrões para cada efeito? Apresente o seu modelo para estimativa do tempo de execução do algoritmo em questão.
- (c) Qual a porcentagem da variação explicada por cada efeito e pelo modelo? Você está satisfeito com seu modelo? Justifique. Qual o seu próximo passo na avaliação do impacto dos fatores CPU, memória e disco no desempenho do algoritmo em questão?
- (d) Com uma confiança de 90%, você poderia dizer que o efeito A é significativamente diferente do efeito C? Justifique.
- (e) Você pode propor um melhor projeto de experimentos, mantendo o mesmo custo, que o proposto acima? Justifique

# Projeto Fatorial Completo com Dois Fatores Sem Replicação

- Dois fatores A e B com a e b níveis respectivamente
  - Fatores são categóricos (ou tratados como tal)
    - Fatores quantitativos: usar regressão
  - Cada experimento é executado somente uma vez
    - Não irá conseguir separar interação de erros experimentais

$$y_{ij} = \mu + \alpha_j + \beta_i + e_{ij}$$

$$\sum_j \alpha_j = 0 \quad \sum_i \beta_i = 0$$

Efeitos dos fatores e erros  
são aditivos

# Cálculo dos efeitos

- Similar ao projeto de 1 fator

$$y_{ij} = \mu + \alpha_j + \beta_i + e_{ij}$$

$$\mu = \overline{y_{..}}$$

$$\alpha_j = \overline{y_{.j}} - \overline{y_{..}}$$

$$\beta_i = \overline{y_{i.}} - \overline{y_{..}}$$

$$\sum_j \alpha_j = 0 \quad \sum_i \beta_i = 0$$

# Exemplo

Tempo de processamento de diferentes cargas em três configurações de cache

Workloads	Two Caches	One Cache	No Cache
ASM	54.0	55.0	106.0
TECO	60.0	60.0	123.0
SIEVE	43.0	43.0	120.0
DHRYSTONE	49.0	52.0	111.0
SORT	49.0	50.0	108.0

# Exemplo

Workloads	Two Caches	One Cache	No Cache	Row Sum	Row Mean	Row Effect
ASM	54.0	55.0	106.0	215.0	71.7	-0.5
TECO	60.0	60.0	123.0	243.0	81.0	8.8
SIEVE	43.0	43.0	120.0	206.0	68.7	-3.5
DHRYSTONE	49.0	52.0	111.0	212.0	70.7	-1.5
SORT	49.0	50.0	108.0	207.0	69.0	-3.2
Column Sum	255.0	260.0	568.0	1083.0		
Column Mean	51.0	52.0	113.6		72.2	
Column effect	-21.2	-20.2	41.4			

Em média: tempo = 72.2 ms ( $\mu$ )

- Tempo com dois caches é em média 21.2 ms menor que a média
- Tempo com um cache é em média 20.2 ms menor que média
- Tempo sem cache é em média 41.44 ms maior que a média
- Carga também afeta: carga ASM gasta 0.5 ms a menos que a média enquanto TECO gasta 8.8 ms a mais que a média

# Estimando "Erros Experimentais"

$$\hat{y}_{ij} = \mu + \alpha_j + \beta_i$$

$$e_{ij} = y_{ij} - \hat{y}_{ij} = y_{ij} - \mu - \alpha_j - \beta_i$$

$$SSE = \sum_{i=1}^b \sum_{j=1}^a e_{ij}^2$$

Para o exemplo:

$$\hat{y}_{11} = \mu + \alpha_1 + \beta_1 = 72.2 - 21.2 - 0.5 = 50.5$$

$$y_{11} = 54$$

$$e_{11} = 3.5$$

# Estimando “Erros Experimentais”

Para o exemplo:

Workloads	Two Caches	One Cache	No Cache
ASM	3.5	3.5	-7.1
TECO	0.2	-0.8	0.6
SIEVE	-4.5	-5.5	9.9
DHRYSTONE	-0.5	1.5	-1.1
SORT	1.2	1.2	-2.4

$$\text{SSE} = (3.5)^2 + (0.2)^2 + \dots (-2.4)^2 = 236.81$$

# Alocação de Variação

$$SST = SSY - SS0 = SSA + SSB + SSE$$

$$SSY = \sum_{ij} y_{ij}^2 = 91595$$

$$SS0 = ab\mu^2 = 3 \times 5 \times (72.2)^2 = 78192.59$$

$$SSA = b \sum_j \alpha_j^2 = 5 \times ((-21.2)^2 + (-20.2)^2 + (41.4)^2) = 12857.2$$

$$SSB = a \sum_i \beta_i^2 = 3 \times ((-0.5)^2 + (8.8)^2 + (-3.5)^2 + (-1.5)^2 + (3.2)^2) = 308.40$$

$$SST = SSY - SS0 = 91595 - 78192.59 = 13402.41$$

$$SSE = SST - SSA - SSB = 236.81$$

$$\%VarA = \frac{SSA}{SST} = 95.9\%$$

$$\%VarB = \frac{SSB}{SST} = 2.3\%$$

$$\%var \text{ inexplicada} = \frac{SSE}{SST} = 1.8\%$$



# ANOVA

- Objetivo: testar significância de um fator usando teste-F
- Graus de liberdade

$$\begin{array}{rccccccccc} SSY & = & SS0 & + & SSA & + & SSB & + & SSE \\ ab & = & 1 & + & (a-1) & + & (b-1) & + & (a-1)(b-1) \end{array}$$

- Means Squares

$$MSA = \frac{SSA}{a-1}$$

$$MSB = \frac{SSB}{b-1}$$

$$MSE = \frac{SSE}{(a-1)(b-1)}$$

$$\frac{MSA}{MSE} \sim F_{[a-1, (a-1)(b-1)]}$$

Se  $\frac{MSA}{MSE} > F_{[1-\alpha, a-1, (a-1)(b-1)]}$  então fator A é significativo com  $(1-\alpha)\%$  de confiança

Se  $\frac{MSB}{MSE} > F_{[1-\alpha, b-1, (a-1)(b-1)]}$  então fator B é significativo com  $(1-\alpha)\%$  de confiança

# Tabela ANOVA

Component	Sum of Squares	% Variation	DF	Mean Square	F-Comp.	F-Table
$y$	$SSY = \sum y_{ij}^2$		$ab$			
$\bar{y}...$	$SS0 = ab\mu^2$		1			
$y - \bar{y}...$	$SST = SSY - SS0$	100	$ab - 1$			
$A$	$SSA = b\sum \alpha_j^2$	$100 \left( \frac{SSA}{SST} \right)$	$a - 1$	$MSA = \frac{SSA}{a-1}$	$\frac{MSA}{MSE}$	$F_{[1-\alpha, a-1, (a-1)(b-1)]}$
$B$	$SSB = a\sum \beta_i^2$	$100 \left( \frac{SSB}{SST} \right)$	$b - 1$	$MSB = \frac{SSB}{b-1}$	$\frac{MSB}{MSE}$	$F_{[1-\alpha, b-1, (a-1)(b-1)]}$
$e$	$SSE = SST - (SSA + SSB)$	$100 \left( \frac{SSE}{SST} \right)$	$(a - 1)(b - 1)$	$MSE = \frac{SSE}{(a-1)(b-1)}$		

# Exemplo: Tabela ANOVA

Component	Sum of Squares	%Variation	DF	Mean Square	F-Comp.	F-Table
y	91595.00					
y..	78192.59					
y-y..	13402.41	100.0%	14			
Caches	12857.20	95.9%	2	6428.60	217.2	3.1
Workloads	308.40	2.3%	4	77.10	2.6	2.8
Errors	236.80	1.8%	8	29.60		


$$s_e = \sqrt{\text{MSE}} = \sqrt{29.60} = 5.44$$

Efeito do cache é significativo

Efeito da carga não é significativo

# Testes Visuais

Mesmo testes usados em projeto de 1 fator



# Intervalos de Confiança

Computar IC para diferentes parâmetros usando graus de liberdade dos erros  $(a-1)(b-1)$

Parameter	Estimate	Variance
$\mu$	$\bar{y}_{..}$	$s_e^2/ab$
$\alpha_j$	$\bar{y}_{.j} - \bar{y}_{..}$	$s_e^2(a-1)/ab$
$\mu + \alpha_j$	$\bar{y}_{.j}$	$s_e^2/b$
$\beta_i$	$\bar{y}_{i.} - \bar{y}_{..}$	$s_e^2(b-1)/ab$
$\mu + \alpha_j + \beta_i$	$\bar{y}_{.j} + \bar{y}_{i.} - \bar{y}_{..}$	$s_e^2(a+b-1)/(ab)$
$\sum_{j=1}^a h_j \alpha_j, \sum_{j=1}^a h_j = 0$	$\sum_{j=1}^a h_j \bar{y}_{.j}$	$s_e^2 \sum_{j=1}^a h_j^2 / b$
$\sum_{i=1}^b h_i \beta_i, \sum_{i=1}^b h_i = 0$	$\sum_{i=1}^b h_i \bar{y}_{i.}$	$s_e^2 \sum_{i=1}^b h_i^2 / a$
$s_e^2$	$\{\sum_{j=1}^a \sum_{i=1}^b e_{ij}^2\} / \{(a-1)(b-1)\}$	

Degrees of freedom for errors =  $(a-1)(b-1)$

# Intervalos de Confiança: Exemplo

Graus de liberdade =  $(a-1)(b-1) = 2*4 = 8$

$t_{0.95,8} = 1.86$      $s_e = 5.44$

Para- meter	Mean Effect	Std. Dev.	Confidence Interval
$\mu$	72.2	1.4	( 69.6, 74.8)
Caches			
Two Caches	-21.2	1.99	( -24.9, -17.5)
One Cache	-20.2	1.99	( -23.9, -16.5)
No Cache	41.4	1.99	( 37.7, 45.1)

# Intervalos de Confiança: Exemplo

Graus de liberdade =  $(a-1)(b-1) = 2*4 = 8$

$t_{0.95,8} = 1.86$      $s_e = 5.44$

Parameter	Mean Effect	Std. Dev.	Confidence Interval
$\mu$	72.2	1.4	( 69.6, 74.8)
Caches			
Two Caches	-21.2	1.99	( -24.9, -17.5)
One Cache	-20.2	1.99	( -23.9, -16.5)
No Cache	41.4	1.99	( 37.7, 45.1)

$$s_{\mu} = \frac{s_e}{\sqrt{ab}} = \frac{5.44}{\sqrt{3 \times 5}}$$

$$s_{\alpha_j} = s_e \sqrt{\frac{a-1}{ab}} = 5.44 \sqrt{\frac{3-1}{3 \times 5}}$$

# Intervalos de Confiança: Exemplo

Graus de liberdade =  $(a-1)(b-1) = 2*4 = 8$

$t_{0.95,8} = 1.86$      $s_e = 5.44$

Parameter	Mean Effect	Std. Dev.	Confidence Interval
ASM	-0.5	2.81	( -5.8, 4.7)†
TECO	8.8	2.81	( 3.6, 14.0)
SIEVE	-3.5	2.81	( -8.8, 1.7)†
DHRYSTONE	-1.5	2.81	( -6.8, 3.7)†
SORT	-3.2	2.81	( -8.4, 2.0)†

†  $\Rightarrow$  Not significant

$$s_{\beta_i} = s_e \sqrt{\frac{b-1}{ab}} = 5.44 \sqrt{\frac{5-1}{3 \times 5}}$$



# Intervalos de Confiança: Exemplo

Graus de liberdade =  $(a-1)(b-1) = 2*4 = 8$

$t_{0.95,8} = 1.86$

IC para diferença dos efeitos de duas configurações de cache alternativas

	Two Caches	One Cache	No Cache
Two Caches		$(-7.4, 5.4)^\dagger$	$(-69.0, -56.2)$
One Cache			$(-68.0, -55.2)$

$^\dagger \Rightarrow$  Not significant

$$s_{\alpha_i - \alpha_j} = s_e \sqrt{\frac{\sum_{j=1}^a h_j^2}{b}} = 5.44 \sqrt{\frac{1^2 + 1^2 + 0^2}{5}}$$

# Outros aspectos

Modelos aditivos X modelos multiplicativos  
ver exemplos no livro

Observações faltantes: generalização das fórmulas quando não tem resultados de experimentos para todas as ab configurações

# Projeto Fatorial Completo com Dois Fatores Com Replicação

- Dois fatores A e B com a e b níveis respectivamente
  - Fatores são categóricos ou tratados como tal
  - Cada experimento é executado múltiplas vezes
  - Permite separar interação de erros experimentais

$y_{ijk} = \mu + \alpha_j + \beta_i + \gamma_{ij} + e_{ijk}$ 
 Efeitos dos fatores e erros são aditivos

$$\begin{aligned}
 \sum_{j=1}^a \alpha_j &= 0 & \sum_{i=1}^b \beta_i &= 0 & \sum_{j=1}^a \gamma_{1j} &= \sum_{j=1}^a \gamma_{2j} = \cdots = \sum_{j=1}^a \gamma_{bj} = 0 \\
 & & & & \sum_{i=1}^b \gamma_{i1} &= \sum_{i=1}^b \gamma_{i2} = \cdots = \sum_{i=1}^b \gamma_{ia} = 0 \\
 & & & & & \cdot \\
 \sum_{k=1}^r e_{ijk} &= 0 & \forall i, j &
 \end{aligned}$$

# Cálculo dos Efeitos

$$y_{ijk} = \mu + \alpha_j + \beta_i + \gamma_{ij} + e_{ijk}$$

$$\overline{y_{ij.}} = \mu + \alpha_j + \beta_i + \gamma_{ij}$$

$$\overline{y_{i..}} = \mu + \beta_i \quad \beta_i = \overline{y_{i..}} - \mu$$

$$\overline{y_{.j.}} = \mu + \alpha_j \longrightarrow \alpha_j = \overline{y_{.j.}} - \mu$$

$$\overline{y_{...}} = \mu \quad \gamma_{ij} = \overline{y_{ij.}} - (\mu + \alpha_j + \beta_i)$$

$$\gamma_{ij} = \overline{y_{ij.}} - (\mu + \overline{y_{.j.}} - \mu + \overline{y_{i..}} - \mu)$$

$$\gamma_{ij} = \overline{y_{ij.}} - \overline{y_{.j.}} - \overline{y_{i..}} + \overline{y_{...}}$$

# Exemplo: Tamanho de código em 5 cargas e 4 computadores

Workloads	Processors			
	W	X	Y	Z
I	7006	12042	29061	9903
	6593	11794	27045	9206
	7302	13074	30057	10035
J	3207	5123	8960	4153
	2883	5632	8064	4257
	3523	4608	9677	4065
K	4707	9407	19740	7089
	4935	8933	19345	6982
	4465	9964	21122	6678
L	5107	5613	22340	5356
	5508	5947	23102	5734
	4743	5161	21446	4965
W	6807	12243	28560	9803
	6392	11995	26846	9306
	7208	12974	30559	10233

# Exemplo: Tamanho de código em 5 cargas e 4 computadores

Workloads	Processors			
	W	X	Y	Z
I	3.8455	4.0807	4.4633	3.9958
	3.8191	4.0717	4.4321	3.9641
	3.8634	4.1164	4.4779	4.0015
J	3.5061	3.7095	3.9523	3.6184
	3.4598	3.7507	3.9066	3.6291
	3.5469	3.6635	3.9857	3.6091
K	3.6727	3.9735	4.2953	3.8506
	3.6933	3.9510	4.2866	3.8440
	3.6498	3.9984	4.3247	3.8246
L	3.7082	3.7492	4.3491	3.7288
	3.7410	3.7743	4.3636	3.7585
	3.6761	3.7127	4.3313	3.6959
M	3.8330	4.0879	4.4558	3.9914
	3.8056	4.0790	4.4289	3.9688
	3.8578	4.1131	4.4851	4.0100

Modelo  
Multiplicativo:  
Transformação  
logarítmica

# Exemplo: Tamanho de código em 5 cargas e 4 computadores

Cálculo das médias das observações por célula

Workloads	Processors				Row Sum	Row Mean	Row Effect
	W	X	Y	Z			
I	3.8427	4.0896	4.4578	3.9871	16.3772	4.0943	0.1520
J	3.5043	3.7079	3.9482	3.6188	14.7792	3.6948	-0.2475
K	3.6720	3.9743	4.3022	3.8397	15.7882	3.9470	0.0047
L	3.7084	3.7454	4.3480	3.7277	15.5295	3.8824	-0.0599
M	3.8321	4.0933	4.4566	3.9900	16.3720	4.0930	0.1507
Col Sum	18.5594	19.6105	21.5128	19.1635	78.8463		
Col Mean	3.7119	3.9221	4.3026	3.8327		3.9423	
Col effect	-0.2304	-0.0202	0.3603	-0.1096			

Modelo multiplicativo:  $y_{ij} = 10^{\mu} 10^{\alpha_j} 10^{\beta_i} 10^{\gamma_{ij}}$

$\mu=3.9423$ : tamanho médio =  $10^{3.9423}=8710$

Processador W requer em média um fator de  $10^{-0.2304}$  a menos

Carga I requer em média um fator de  $10^{0.1520}$  a mais

# Exemplo: Tamanho de código em 5 cargas e 4 computadores

Cálculo dos efeitos das interações:

$$\overline{y_{ij.}} = \mu + \alpha_j + \beta_i + \gamma_{ij}$$

$$\gamma_{ij} = \overline{y_{ij.}} - (\mu + \alpha_j + \beta_i)$$

Workloads	W	X	Y	Z
I	-0.0212	0.0155	0.0032	0.0024
J	0.0399	0.0333	-0.1069	0.0337
K	-0.0447	0.0475	-0.0051	0.0023
L	0.0564	-0.1168	0.1054	-0.0450
M	-0.0305	0.0205	0.0033	0.0066

Soma das linhas/colunas tem que dar 0



# Exemplo: Tamanho de código em 5 cargas e 4 computadores

Cálculo dos efeitos das interações:

$$\overline{y_{ij.}} = \mu + \alpha_j + \beta_i + \gamma_{ij}$$

$$\gamma_{ij} = \overline{y_{ij.}} - (\mu + \alpha_j + \beta_i)$$

Workloads	W	X	Y	Z
I	-0.0212	0.0155	0.0032	0.0024
J	0.0399	0.0333	-0.1069	0.0337
K	-0.0447	0.0475	-0.0051	0.0023
L	0.0564	-0.1168	0.1054	-0.0450
M	-0.0305	0.0205	0.0033	0.0066

Interpretação: carga I no processador W requer um fator de  $10^{(-0.0212)}$  a menos que a média das cargas no processador W. Mesma coisa quando comparado à média dos tamanhos da carga I em todos os processadores

# Alocação de Variação

$$\hat{y}_{ij} = \mu + \alpha_j + \beta_i + \gamma_{ij} = \bar{y}_{ij}. \quad e_{ijk} = y_{ijk} - \bar{y}_{ij}.$$

$$\begin{array}{rclclclclcl} \sum_{ijk} y_{ijk}^2 & = & abr\mu^2 & + & br \sum_j \alpha_j^2 & + & ar \sum_i \beta_i^2 & + & r \sum_{ij} \gamma_{ij}^2 & + & \sum_{ijk} e_{ijk}^2 \\ SSY & = & SS0 & + & SSA & + & SSB & + & SSAB & + & SSE \end{array}$$

$$\begin{array}{rclclclclcl} SST & = & SSY & - & SS0 & = & SSA & + & SSB & + & SSAB & + & SSE \\ 4.44 & = & 936.95 & - & 932.51 & = & 2.93 & + & 1.33 & + & 0.15 & + & 0.03 \\ 100\% & = & & & & = & 65.96\% & + & 29.9\% & + & 3.48\% & + & 0.66\% \end{array}$$

# ANOVA

Graus de liberdade:

$$\begin{array}{rcl} \text{SSY} & = & \text{SS0} + \text{SSA} + \text{SSB} + \text{SSAB} + \text{SSE} \\ \text{abr} & = & 1 + (a-1) + (b-1) + (a-1)(b-1) + ab(r-1) \end{array}$$

$$\frac{\text{MSA}}{\text{MSE}} \sim F[a-1, ab(r-1)]$$

$$\frac{\text{MSB}}{\text{MSE}} \sim F[b-1, ab(r-1)]$$

$$\square \quad \frac{\text{MSAB}}{\text{MSE}} \sim F[(a-1)(b-1), ab(r-1)]$$

# Tabela ANOVA

Component	Sum of Squares	%Variation	DF	Mean Square	F-Comp.	F-Table
$y$	$SSY = \sum y_{ij}^2$		$abr$			
$\bar{y}_{...}$	$SS0 = abr\mu^2$		1			
$y - \bar{y}_{...}$	$SST = SSY - SS0$	100	$abr - 1$			
$A$	$SSA = br\sum\alpha_j^2$	$100 \left( \frac{SSA}{SST} \right)$	$a - 1$	$MSA = \frac{SSA}{a-1}$	$\frac{MSA}{MSE}$	$F_{[1-\alpha; a-1, ab(r-1)]}$
$B$	$SSB = ar\sum\beta_i^2$	$100 \left( \frac{SSB}{SST} \right)$	$b - 1$	$MSB = \frac{SSB}{b-1}$	$\frac{MSB}{MSE}$	$F_{[1-\alpha; b-1, ab(r-1)]}$
$AB$	$SSAB = r\sum\gamma_{ij}^2$	$100 \left( \frac{SSAB}{SST} \right)$	$(a - 1)(b - 1)$	$MSAB = \frac{SSAB}{(a-1)(b-1)}$	$\frac{MSA}{MSE}$	$F_{[1-\alpha, (a-1)(b-1), ab(r-1)]}$
$e$	$SSE = SST - (SSA + SSB + SSAB)$	$100 \left( \frac{SSE}{SST} \right)$	$ab(r - 1)$	$MSE = \frac{SSE}{ab(r-1)}$		

# Tabela ANOVA: exemplo

Component	Sum of Squares	%Variation	DF	Mean Square	F-Comp.	F-Table
$y$	936.95					
$\bar{y}_{...}$	932.51					
$y - \bar{y}_{...}$	4.44	100.00%	59			
Processors	2.93	65.96%	3	0.9765	1340.01	2.23
Workloads	1.33	29.90%	4	0.3320	455.65	2.09
Interactions	0.15	3.48%	12	0.0129	17.70	1.71
Errors	0.03	0.66%	40	0.0007		
$s_e = \sqrt{\text{MSE}} = \sqrt{0.0008} = 0.03$						

Os dois fatores e a interação são significativos com 90% de confiança

# Intervalos de Confiança

Parameter	Estimate	Variance
$\mu$	$\bar{y}_{...}$	$s_e^2/abr$
$\alpha_j$	$\bar{y}_{i..}-\bar{y}_{...}$	$s_e^2(a-1)/abr$
$\beta_i$	$\bar{y}_{.j.}-\bar{y}_{...}$	$s_e^2(b-1)/abr$
$\gamma_{ij}$	$\bar{y}_{ij.}-\bar{y}_{i..}-\bar{y}_{.j.}+\bar{y}_{...}$	$s_e^2(a-1)(b-1)/abr$
$\sum h_j \alpha_j, \sum h_j=0$	$\sum h_j \bar{y}_{.j.}$	$\sum h_j^2 s_e^2/br$
$\sum h_i \beta_i, \sum h_i=0$	$\sum h_i \bar{y}_{i..}$	$\sum h_i^2 s_e^2/ar$
$s_e^2$	$\sum e_{ijk}^2/\{ab(r-1)\}$	
Degrees of freedom for errors = $ab(r-1)$		

# Intervalos de Confiança: exemplo

$$s_{\alpha_j} = s_e \sqrt{\frac{a-1}{abr}} = 0.03 \sqrt{\frac{4-1}{4 \times 5 \times 3}} = 0.0060$$

Graus de liberdade:  $ab(r-1) = 40$  (use distr. Normal)

Para 90% de confiança  $= z_{0.95} = 1.645$

$$\begin{aligned}\alpha_1 \mp t s_{\alpha_1} &= -0.2304 \mp 1.645 \times 0.0060 \\ &= -0.2304 \mp 0.00987 \\ &= (-0.2406, -0.2203)\end{aligned}$$

Significativo!

# Intervalos de Confiança: exemplo

Parameter	Mean Effect	Std. Dev.	Confidence Interval
$\mu$	3.9423	0.0035	( 3.9364, 3.9482)

## Processors

W	-0.2304	0.0060	( -0.2406, -0.2203)
X	-0.0202	0.0060	( -0.0304, -0.0100)
Y	0.3603	0.0060	( 0.3501, 0.3704)
Z	-0.1096	0.0060	( -0.1198, -0.0995)

## Workloads

I	0.1520	0.0070	( 0.1402, 0.1637)
J	-0.2475	0.0070	( -0.2592, -0.2358)
K	0.0047	0.0070	( -0.0070, 0.0165)†
L	-0.0599	0.0070	( -0.0717, -0.0482)
M	0.1507	0.0070	( 0.1390, 0.1624)

†  $\Rightarrow$  Not significant



# Intervalos de Confiança: exemplo

Workloads	W	X	Y	Z
I	( -0.0415, -0.0009)	( -0.0048, 0.0358)†	( -0.0171, 0.0236)†	( -0.0179, 0.0228)†
J	( 0.0196, 0.0602)	( 0.0130, 0.0536)	( -0.1272, -0.0865)	( 0.0133, 0.0540)
K	( -0.0650, -0.0243)	( 0.0271, 0.0678)	( -0.0254, 0.0152)†	( -0.0180, 0.0226)†
L	( 0.0361, 0.0768)	( -0.1371, -0.0964)	( 0.0850, 0.1257)	( -0.0654, -0.0247)
M	( -0.0508, -0.0101)	( 0.0002, 0.0408)	( -0.0170, 0.0236)†	( -0.0137, 0.0270)†

†  $\Rightarrow$  Not significant

Mesmos testes visuais!!!